

Estimação por Máxima Verossimilhança e Simulação de Monte Carlo

Um Estudo sobre a Distribuição Gama

Matheus Diogo Rocha da Silva e Matheus Pereira Costa

Sumário

- 1 Introdução do Estudo
- 2 Características e Aplicações da Distribuição Gama
- 3 Função de Verossimilhança e Log-verossimilhança
- 4 Vetor Escore e Equações de Máxima Verossimilhança
- 5 Informação de Fisher
- 6 Obtenção dos Estimadores de Máxima Verossimilhança
- 7 Experimento de Monte Carlo
- 8 Resultados da Simulação
- 9 Conclusão do Estudo

Introdução do Estudo

O objetivo deste trabalho é realizar um estudo sobre os estimadores de Máxima Verossimilhança para os parâmetros de forma α e de escala β do modelo probabilístico Gama, avaliando suas propriedades analiticamente e computacionalmente por simulação de Monte Carlo, sendo integralmente implementado pela linguagem R.

O acesso ao código da simulação faz-se pelo repositório do [Github](#).

Entretanto, antes de prosseguir ao dado objetivo, torna-se necessário contextualizar a distribuição gama quanto as suas características e aplicações.

Definição do Modelo Probabilístico

Seja X uma V.A. contínua. Se X está associado à uma f.d.p. dada por

$$f(x|\alpha, \beta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right), \quad x > 0, \quad \alpha > 0 \text{ e } \beta > 0,$$

em que $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} \exp(-x) dx$, $\alpha > 0$,

temos que X tem distribuição Gama, denotando-se por $X \sim \text{Gama}(\alpha, \beta)$.

Além disso, define-se que o espaço paramétrico $\Theta = \{(\alpha, \beta) \in \mathbb{R}^2 \mid \alpha > 0 \text{ e } \beta > 0\}$.


Observação

Neste trabalho, será estudado a distribuição Gama com parametrização de β como uma escala.


Interpretação dos Parâmetros α e β

O parâmetro de forma α desloca a região central da distribuição, enquanto o parâmetro de escala β alonga a cauda à direita da distribuição. As figuras abaixo ilustram essas mudanças.

Comparativo das f.d.p.s com Forma Variada e Escala Fixa



Comparativo das f.d.p.s com Forma Fixa e Escala Variada



Aplicações do Modelo Probabilístico

A distribuição Gama é apropriada para modelar variáveis contínuas e positivas cujas hajam assimetria positiva. Dentre as várias aplicações, pode-se catalogar:

- Estudo de dados pluviométricos para pesquisas climáticas e de agricultura;




Figura: Precipitação Média por Decênio. Goiana, Pernambuco, 1981-2009.

- Análise de sobrevivência na medicina pelo tempo de vida de pacientes em enfermidade;
- Estimação da vida útil de determinada componente ou tempo de falha de um sistema.

Função de Verossimilhança e Log-verossimilhança

Para $X_1, \dots, X_n$ uma A.A. de $X \sim \text{Gama}(\alpha, \beta)$, a função de verossimilhança é

$$L(\alpha, \beta; \underset{\sim}{x}) = \frac{1}{[\Gamma(\alpha)]^n \beta^{n\alpha}} \left(\prod_{i=1}^n x_i \right)^{\alpha-1} \exp \left(-\frac{1}{\beta} \sum_{i=1}^n x_i \right).$$

Aplicado o logaritmo, obtemos a log-verossimilhança expressa por

$$\ell(\alpha, \beta) = -n \ln \Gamma(\alpha) - n\alpha \ln \beta + (\alpha - 1) \sum_{i=1}^n \ln(x_i) - \frac{1}{\beta} \sum_{i=1}^n x_i.$$

Construção do Vetor Escore

O vetor escore é dado por

$$U(\underset{\sim}{\theta}) = \begin{pmatrix} \frac{\partial \ell}{\partial \alpha} \\ \frac{\partial \ell}{\partial \beta} \end{pmatrix},$$

em que $\underset{\sim}{\theta} = \begin{pmatrix} \alpha \\ \beta \end{pmatrix}$ é o vetor paramétrico.

As derivadas da log-verossimilhança são

$$\frac{\partial \ell}{\partial \alpha} = -n\psi(\alpha) - n \ln \beta + \sum_{i=1}^n \ln(x_i) \text{ e } \frac{\partial \ell}{\partial \beta} = -\frac{n\alpha}{\beta} + \frac{1}{\beta^2} \sum_{i=1}^n x_i.$$

Observação

$$\psi(\alpha) = \frac{d}{d\alpha} \ln \Gamma(\alpha)$$

é a função digama.

Vetor Escore e Equações de Máxima Verossimilhança

Portanto,

$$U(\underset{\sim}{\theta}) = \begin{pmatrix} -n\psi(\alpha) - n \ln \beta + \sum_{i=1}^n \ln(x_i) \\ -\frac{n\alpha}{\beta} + \frac{1}{\beta^2} \sum_{i=1}^n x_i \end{pmatrix}.$$

Os estimadores de máxima verossimilhança são obtidos por

$$U(\underset{\sim}{\theta}) = \underset{\sim}{0}.$$

Assim, temos o sistema

$$\begin{cases} -n\psi(\hat{\alpha}) - n \ln \hat{\beta} + \sum_{i=1}^n \ln(x_i) = 0, \\ -\frac{n\hat{\alpha}}{\hat{\beta}} + \frac{1}{\hat{\beta}^2} \sum_{i=1}^n x_i = 0. \end{cases}$$

Estimadores de Máxima Verossimilhança

A equação associada a β pode ser resolvida explicitamente, resultando em

$$\hat{\beta} = \frac{\bar{x}}{\hat{\alpha}}.$$

Portanto, $\hat{\beta}$ possui forma fechada, condicionada ao valor de $\hat{\alpha}$.

Para α , após substituir a expressão de $\hat{\beta}$, obtém-se

$$\ln(\hat{\alpha}) - \psi(\hat{\alpha}) = \ln(\bar{x}) - \frac{1}{n} \sum_{i=1}^n \ln(x_i).$$

Essa equação não possui solução analítica explícita para $\hat{\alpha}$, sendo necessária sua obtenção por um **método numérico**.

Matriz Hessiana

A matriz Hessiana é dada pela expressão

$$H(\underset{\sim}{\theta}) = \begin{pmatrix} \frac{\partial^2 \ell}{\partial \alpha^2} & \frac{\partial^2 \ell}{\partial \alpha \partial \beta} \\ \frac{\partial^2 \ell}{\partial \beta \partial \alpha} & \frac{\partial^2 \ell}{\partial \beta^2} \end{pmatrix}.$$

Então, encontradas as respectivas derivadas parciais, temos que

$$H(\underset{\sim}{\theta}) = \begin{pmatrix} -n\varphi(\alpha) & -\frac{n}{\beta} \\ -\frac{n}{\beta} & \frac{n\alpha}{\beta^2} - \frac{2\sum_{i=1}^n x_i}{\beta^3} \end{pmatrix}.$$

Observação

$$\varphi(\alpha) = \frac{\partial}{\partial \alpha} \psi(\alpha)$$

é a função trigama.

E seja a matriz de informação de Fisher dada por

$$I(\theta) = -E_{\theta}[H(\theta)].$$

Determina-se que

$$I(\theta) = \begin{pmatrix} n\varphi(\alpha) & \frac{n}{\beta} \\ \frac{n}{\beta} & \frac{n\alpha}{\beta^2} \end{pmatrix}.$$

Distribuição Assintótica dos Estimadores de Máxima Verossimilhança

Sob as condições de regularidade, em amostras suficientemente grandes, tem-se que

$$\hat{\theta}_{\sim} \overset{a}{\sim} N_2 \left(\theta_{\sim}, I \left(\theta_{\sim} \right)^{-1} \right),$$

em que $\hat{\theta}_{\sim} = \begin{pmatrix} \hat{\alpha} \\ \hat{\beta} \end{pmatrix}$ é o vetor de estimadores e $I \left(\theta_{\sim} \right)^{-1}$ é a inversa da $I \left(\theta_{\sim} \right)$.

Então obtemos que

$$\hat{\theta}_{\sim} \overset{a}{\sim} N_2 \left(\theta_{\sim}, \begin{pmatrix} \frac{1}{n\varphi(\alpha) - n/\alpha} & -\frac{\beta}{n\alpha\varphi(\alpha) - n} \\ -\frac{\beta}{n\alpha\varphi(\alpha) - n} & \frac{\varphi(\alpha)\beta^2}{n\alpha\varphi(\alpha) - n} \end{pmatrix} \right).$$

Assim, a inversa da matriz de Informação de Fisher fornece a matriz de variâncias e covariâncias assintóticas dos estimadores.

Obtenção dos Estimadores de Máxima Verossimilhança

A estimação dos parâmetros foi implementada no software R, utilizando as equações de máxima verossimilhança obtidas analiticamente. Para estimar α , utilizou-se a função `uniroot()`, que implementa o método de Brent, que combina a bisseção, o método da secante e a interpolação quadrática inversa para encontrar numericamente uma raiz de uma função contínua (BRENT, 1973).

Para sua aplicação, fornece-se um intervalo $[a, b]$ no qual a função apresente mudança de sinal,

$$f(a) \cdot f(b) < 0.$$

A função `uniroot()` retorna uma aproximação numérica para a raiz encontrada nesse intervalo.

Aplicação do Método à Distribuição Gama

Para estimar α , aplicou-se o método de Brent à equação de máxima verossimilhança obtida anteriormente. Inicialmente, adotou-se o intervalo $[0,1; 10]$. Caso não houvesse mudança de sinal nos extremos, o intervalo era ampliado até permitir a aplicação do método.

A raiz encontrada pela função `uniroot()` corresponde à estimativa numérica $\hat{\alpha}$. Como a equação de máxima verossimilhança para α possui uma única raiz positiva, a solução encontrada corresponde ao estimador de forma procurado. Após obter $\hat{\alpha}$, o estimador de escala é calculado diretamente por

$$\hat{\beta} = \frac{\bar{x}}{\hat{\alpha}}.$$

Assim, os dois estimadores são obtidos para cada amostra simulada.

Experimento de Monte Carlo

Para avaliar o comportamento dos estimadores de máxima verossimilhança, realizou-se uma simulação de Monte Carlo no software R.

Parâmetros Verdadeiros

$$\alpha = 4 \quad \beta = 3$$

- 1 **Tamanhos amostrais:** $n \in \{20, 30, 50, 100, 200\}$.
- 2 **Número de réplicas:** 10.000 para cada tamanho amostral, denotada pela variável R , totalizando 50.000 amostras simuladas.
- 3 **Procedimento:** em cada réplica, gerou-se uma amostra da distribuição Gama, calcularam-se $\hat{\alpha}$ e $\hat{\beta}$ e registraram-se as estimativas.

CrITÉRIOS para a Avaliação dos Estimadores

Para avaliar as estimativas obtidas nas amostras simuladas, utilizou-se, agrupando os resultados por tamanho amostral, os seguintes critérios:

- média das estimativas, $\bar{\hat{\theta}}_j = \frac{1}{R} \sum_{r=1}^R \hat{\theta}_{jr}$,
- viés, $\text{Bias}(\hat{\theta}_j) = \bar{\hat{\theta}}_j - \theta_{j0}$,
- viés relativo percentual, $\text{RB}(\hat{\theta}_j) = 100 \frac{\bar{\hat{\theta}}_j - \theta_{j0}}{\theta_{j0}}$,
- variância de Monte Carlo, $\text{Var}_{MC}(\hat{\theta}_j) = \frac{1}{R-1} \sum_{r=1}^R \left(\hat{\theta}_{jr} - \bar{\hat{\theta}}_j \right)^2$,
- erro quadrático médio, $\text{EQM}(\hat{\theta}_j) = \frac{1}{R} \sum_{r=1}^R \left(\hat{\theta}_{jr} - \theta_{j0} \right)^2$.

De tal forma que $\theta_1 = \alpha$ e $\theta_2 = \beta$ representam os parâmetros em estudo.

Média das Estimativas

As médias das estimativas obtidas pelos estimadores $\hat{\alpha}$ e $\hat{\beta}$ indicaram, dado o aumento do tamanho amostral, uma convergência para os parâmetros $\alpha = 4$ e $\beta = 3$. Então esse resultado evidencia a possibilidade dos estimadores serem consistentes.

tamanho_amostr	med_est_alpha	med_est_beta
20	4.70390257596381	2.8273028213302
30	4.41859304243134	2.8997306985754
50	4.25707648354148	2.9284378001786
100	4.11731922909218	2.9697178864912
200	4.04886254960582	2.9899585419347

Viés das Estimativas

Os vieses das estimativas dos estimadores $\hat{\alpha}$ e $\hat{\beta}$ apresentaram uma diminuição conforme aumenta-se o tamanho amostral. Novamente, percebe-se uma evidência da consistência dos estimadores em estudo.

tamanho_amostrai	vies_est_alpha	vies_est_beta
20	0.703902575963806	-0.172697178669804
30	0.418593042431336	-0.100269301424600
50	0.257076483541479	-0.071562199821417
100	0.117319229092185	-0.030282113508789
200	0.048862549605824	-0.010041458065297

Viés Relativo Percentual das Estimativas

Os vieses relativos percentuais das estimativas com estimadores $\hat{\alpha}$ e $\hat{\beta}$, como representação da magnitude dos vieses em grandeza do verdadeiro valor dos parâmetros, implicaram a mesma interpretação dada no critério anteriormente abordado.

tamanho_amostral	vies_rel_est_alpha	vies_rel_est_beta
20	17.5975643990951	-5.75657262232681
30	10.4648260607834	-3.34231004748668
50	6.42691208853698	-2.38540666071391
100	2.93298072730461	-1.00940378362631
200	1.22156374014559	-0.33471526884323

Variância de Monte Carlo das Estimativas

As variâncias de Monte Carlo das estimativas obtidas pelos estimadores $\hat{\alpha}$ e $\hat{\beta}$ mostraram uma diminuição da variação quadrática ao redor das respectivas médias das estimativas, com a elevação do tamanho amostral. Assim, os valores estimados dos parâmetros passaram à ficar mais centralizados nas suas médias cujas as mesmas denotaram uma convergência.

tamanho_amostral	var_mc_est_alpha	var_mc_est_beta
20	2.77637168286686	0.873118752247756
30	1.46572921790453	0.606061176246105
50	0.73994015076434	0.362885100996143
100	0.33364243321574	0.187411210499592
200	0.15124485440079	0.090779098863937


Erro Quadrático Médio das Estimativas

Os erros quadráticos médios das estimativas dos estimadores $\hat{\alpha}$ e $\hat{\beta}$, segundo o aumento do tamanho amostral, manifestaram uma contínua diminuição. Portanto, a precisão das estimativas para os verdadeiros valores dos parâmetros tornou-se melhor com mais observações nas amostras.

tamanho_amostral	eqm_est_alpha	eqm_est_beta
20	2.92249650828090	0.919072370787111
30	1.51627160472882	0.626959837495971
50	0.75504097016769	0.370290919383819
100	0.33701255880378	0.189304253029891
200	0.15200487879477	0.091235275240138

Aproximação da Distribuição Assintótica do Estimador de α


Pela análise dos histogramas das estimativas de α , dado tamanho amostral, é notável que a distribuição das estimativas obtidas aproxima-se da distribuição assintótica do estimador.




Aproximação da Distribuição Assintótica do Estimador de α

Nos gráficos Q-Q das estimativas de α , dado tamanho amostral, é notável que a adequação da distribuição das estimativas melhora assintoticamente desde a região central até as caudas.


De amostras com 20 observações




De amostras com 30 observações




De amostras com 50 observações



De amostras com 100 observações




De amostras com 200 observações



Aproximação da Distribuição Assintótica do Estimador de β


Pela análise dos histogramas das estimativas de β , dado tamanho amostral, é notável que a distribuição das estimativas obtidas aproxima-se da distribuição assintótica do estimador.




Aproximação da Distribuição Assintótica do Estimador de β

Nos gráficos Q-Q das estimativas de β , dado tamanho amostral, é notável que a adequação da distribuição das estimativas melhora assintoticamente desde a região central até as caudas.


De amostras com 20 observações




De amostras com 30 observações




De amostras com 50 observações



De amostras com 100 observações



De amostras com 200 observações



Conclusão do Estudo

O estudo permitiu obter os estimadores de máxima verossimilhança dos parâmetros de forma e escala da distribuição Gama, combinando a abordagem analítica com a implementação computacional no R.

Nas simulações de Monte Carlo, observou-se que:

- As médias das estimativas de α e β aproximaram-se dos respectivos parâmetros verdadeiros à medida que o tamanho amostral aumentou.
- Os vieses diminuíram em magnitude e as variâncias de Monte Carlo foram reduzidas, indicando estimativas menos dispersas e com menores desvios médios.
- Os valores apresentados na tabela de erro quadrático médio também diminuíram com o aumento do tamanho amostral.
- Os histogramas e os gráficos Q-Q mostraram que as distribuições das estimativas de $\hat{\alpha}$ e $\hat{\beta}$ se aproximaram das respectivas distribuições assintóticas conforme o tamanho amostral aumentou, com melhora da adequação também nas regiões de cauda.

De forma geral, os resultados observados foram compatíveis com o comportamento assintótico esperado dos estimadores de máxima verossimilhança, mostrando a importância do tamanho amostral na precisão e na aproximação assintótica das estimativas dos parâmetros da distribuição Gama.

Referências Bibliográficas

MORETTIN, P. A; BUSSAB, W. O. **Estatística Básica**. 6. ed. São Paulo: Saraiva, 2010.

SILVA, A. P. N. et al. **Valores efetivos de precipitação pluvial para manejo da irrigação na cana-de-açúcar em Goiana, Pernambuco**. Agrária - Revista Brasileira de Ciências Agrárias, [S. l.], v. 5, n. 4, p. 585-591, 2022. DOI: 10.5039/agraria.v5i4a980. Disponível em: www.agraria.pro.br. Acesso em: 16 set. 2026.

BOLDRINI, J. L. et al. **Álgebra Linear**. 3. ed. São Paulo: Harper & Row do Brasil, 1980.

BRENT, R. P. **Algorithms for Minimization without Derivatives**. Englewood Cliffs: Prentice-Hall, 1973.

R CORE TEAM. **uniroot: One Dimensional Root (Zero) Finding**. R Documentation, pacote stats. Disponível em: [Documentação oficial do R](#). Acesso em: 22 set. 2026.